



Universidade Estadual de Campinas
Instituto de Matemática, Estatística e Computação Científica
Departamento de Estatística



Análise de Séries Temporais

Modelagem e Previsão da concentração de dióxido de carbono (CO_2) encontrado na atmosfera dos dados do observatório de Mauna Loa - Havaí

CAMPINAS

2026

Lista de Figuras

1	Série temporal da concentração de CO_2	12
2	Heatmap sem tendência concentração de CO_2	14
3	Série temporal decomposta da concentração de CO_2	16
4	Avaliação residual da decomposição STL	17
5	Série temporal da concentração de CO_2 diferenciada	17
6	Diagnóstico de resíduos modelo SARIMA	20
7	Teste para ruído branco modelo SARIMA	21
8	Diagnóstico de resíduos modelo ETS	22
9	Teste para ruído branco modelo ETS	23
10	Previsão modelo SNAIVE da concentração de CO_2	24
11	Previsão modelo ETS da concentração de CO_2	25
12	Previsão modelo SARIMA da concentração de CO_2	26

Lista de Tabelas

1	Estatísticas descritivas da concentração de CO_2	13
2	Média e desvio padrão mensal da concentração de CO_2	13
3	Resultados do Teste de Dickey-Fuller Aumentado	15
4	Resultados do Teste KPSS	15
5	Hipóteses dos testes ADF e KPSS	15
6	Resultados dos testes de estacionariedade para a série diferenciada	18
7	Critérios de informação dos modelos candidatos	19
8	Critérios de previsão dos modelos avaliados.	19
9	Resultados do teste de Ljung-Box para os modelos ajustados	23
10	Parâmetros estimados do modelo ETS (M,Ad,M)	25
11	Parâmetros estimados do modelo SARIMA(1,1,1)(1,1,2) ₁₂	26

Conteúdo

1	Introdução	5
2	Objetivo	5
3	Resumo	5
4	Dados	5
4.1	Importação e limpeza dos dados	6
4.2	Reprodutibilidade dos dados localmente	6

5	Metodologia	6
5.1	Fonte dos dados	6
5.2	Descrição das variáveis	6
5.3	Análise inferencial	6
5.4	Testes estatísticos	6
5.5	Estrutura da série temporal	8
5.6	Critérios de informação	8
5.7	Modelos candidatos	9
5.7.1	SNAIVE	9
5.7.2	ETS	9
5.7.3	ARIMA	9
5.7.4	SARIMA	10
5.8	Critérios de previsão	10
5.9	Avaliação residual dos modelos ajustados	11
5.10	Versão utilizada do Rstudio	12
6	Resultados	12
6.1	Série temporal da concentração de CO_2	12
6.2	Estatística resumo	12
6.2.1	Estatística resumo da concentração de CO_2	12
6.3	Identificação de padrões sazonais	13
6.3.1	Dados mensais, média e desvio padrão – concentração CO_2	13
6.4	Gráfico Heatmap	14
6.5	Avaliando a estacionariedade da série temporal	14
6.5.1	Teste de Dickey-Fuller Aumentado (ADF)	14
6.5.2	Teste de Kwiatkowski-Phillips-Schmidt-Shin (KPSS)	15
6.6	Série temporal decomposta – concentração CO_2	15
6.6.1	Métodos de decomposição	15
6.6.2	Estrutura do modelo da série (Aditiva)	16
6.7	Gráfico dos resíduos e FAC da decomposição do modelo STL	16
6.8	Série temporal da concentração de CO_2 com diferenciação	17
6.9	Avaliando a estacionariedade da série temporal com diferenciação	18
6.9.1	Teste de Dickey-Fuller Aumentado (ADF)	18
6.10	Análise inferencial	18
6.10.1	Critérios de informação	18
6.11	Critério de previsão dos modelos	19
6.11.1	EPM, EQM, EAM e EPAM	19
6.12	Diagnóstico dos resíduos	20
6.12.1	Resíduos do modelo – SARIMA	20
6.13	Testes de Portmanteau – Box-Pierce e Ljung-Box	21
6.13.1	Ruído branco – SARIMA	21
6.13.2	Resíduos do modelo – ETS	21

6.13.3	Ruído branco – ETS	22
6.14	Resultados do teste de Ljung-Box para os modelos ajustados	23
6.15	Previsões dos modelos – SNAIVE, SARIMA e ETS	24
6.15.1	Previsão do modelo benchmark SNAIVE	24
6.15.2	Parâmetros estimados modelo ETS	24
6.15.3	Previsão do modelo ETS	25
6.15.4	Parâmetros estimados modelo SARIMA	25
6.15.5	Previsão do modelo SARIMA	26
7	Conclusão	27

1 Introdução

A análise de séries temporais desempenha um papel fundamental na compreensão de fenômenos que evoluem ao longo do tempo, especialmente em contextos ambientais e climáticos. Entre esses fenômenos, a concentração de dióxido de carbono (CO_2) na atmosfera tem recebido grande atenção devido à sua relação direta com mudanças climáticas e aquecimento global.

Neste trabalho, será analisada a série temporal das concentrações mensais de CO_2 medidas no observatório de Mauna Loa, uma das mais conhecidas e utilizadas na literatura. Essa série apresenta características relevantes, como tendência crescente ao longo do tempo e padrões sazonais recorrentes, o que a torna adequada para a aplicação de diferentes métodos de modelagem em séries temporais.

2 Objetivo

O objetivo principal é modelar e prever a série temporal de concentração de CO_2 por meio de diferentes abordagens estatísticas, incluindo os modelos SNAIVE, ETS, ARIMA, SARIMA. Além disso, busca-se comparar o desempenho desses modelos com base em critérios de ajuste, medidas de previsão e análises diagnósticas dos resíduos. Dessa forma, pretende-se identificar o modelo mais adequado para representar a dinâmica da série e produzir previsões consistentes para períodos futuros.

3 Resumo

No presente relatório foi realizada uma análise completa da série temporal de concentração mensal de CO_2 , com o objetivo de compreender sua dinâmica temporal e avaliar diferentes métodos de previsão. Inicialmente, foram conduzidas análises exploratórias para identificar padrões de tendência, sazonalidade e possíveis comportamentos atípicos da série.

Em seguida, foi aplicada a decomposição STL, permitindo visualizar separadamente as componentes de tendência, sazonalidade e resíduos da análise da série, contemplando etapas de exploração dos dados, decomposição STL, avaliação da estacionariedade, ajuste de modelos e geração de previsões. Foram comparados os modelos SNAIVE, ETS, ARIMA e SARIMA por meio de critérios de informação, métricas de previsão e análise residual.

Os resultados indicaram que os modelos ETS (M,Ad,M) e SARIMA (1,1,1)(1,1,2)₁₂ apresentaram os melhores desempenhos, superando o modelo SNAIVE. Os diagnósticos dos resíduos e os testes de Ljung-Box confirmaram a adequação dos ajustes realizados. Por fim, as previsões obtidas preservaram a tendência crescente e a sazonalidade anual da série, sendo o modelo SARIMA adotado como modelo final para fins de previsão.

4 Dados

Para cumprir os objetivos deste trabalho, dispomos de dados provenientes do Rstudio, chamado CO_2 e trata-se de uma análise que inclui informações sobre concentrações atmosféricas

de dióxido de carbono (CO_2) utilizando-se dados mensais observados no observatório de Mauna Loa (Havaí) ao longo do período 1959-1997. O *dataset* **co2** nos traz registros de informações de 468 observações e apenas 1 variável.

4.1 Importação e limpeza dos dados

Na etapa de importação dos dados, verificou-se a inexistência de observações faltantes. Além disso, não foram necessários procedimentos de limpeza, tratamento ou reorganização dos dados, visto que a base apresentava-se consistente, completa e adequada para a realização das análises.

4.2 Reprodutibilidade dos dados localmente

Para cumprir os objetivos deste trabalho, foram utilizados dados provenientes do ambiente Rstudio, por meio do conjunto de dados **co2**. Essa base contém registros da concentração atmosférica mensal de dióxido de carbono (CO_2) medidos no Observatório de Mauna Loa, localizado no Havaí. O conjunto de dados compreende observações mensais realizadas entre os anos de 1959 e 1997, totalizando 468 observações. Como se trata de uma série temporal univariada, a base é composta por uma única variável, correspondente à concentração média mensal de CO_2 , expressa em partes por milhão (ppm).

5 Metodologia

5.1 Fonte dos dados

Fonte: conjunto de dados *co2*, disponível no pacote *datasets* do Rstudio.

5.2 Descrição das variáveis

CO_2 : Concentração média mensal de dióxido de carbono (CO_2) na atmosfera, medida no Observatório de Mauna Loa, localizado no Havaí, expressa em partes por milhão (ppm).

5.3 Análise inferencial

5.4 Testes estatísticos

Augmented Dickey-Fuller Test (ADF):

$$\Delta Z_t = \alpha + \beta t + \gamma Z_{t-1} + \sum_{i=1}^p \delta_i \Delta Z_{t-i} + \varepsilon_t \quad (1)$$

onde:

- ΔZ_t é a primeira diferença da série Z_t
- α é o intercepto (constante)
- β é o coeficiente associado ao termo de tendência temporal t

- γ é o coeficiente associado ao termo defasado Z_{t-1} , utilizado para testar a presença da raiz unitária
- δ_i são os coeficientes das defasagens das primeiras diferenças, incluídos para controlar a autocorrelação serial
- ε_t é o termo de erro aleatório, assumido como ruído branco

O teste ADF utiliza as seguintes hipóteses:

- Hipótese Nula (H_0): A série apresenta raiz unitária (série não estacionária, $\gamma = 0$)
- Hipótese Alternativa (H_1): A série é estacionária ($\gamma < 0$)

Kwiatkowski-Phillips-Schmidt-Shin (KPSS):

$$y_t = \delta t + r_t + \varepsilon_t, \quad r_t = r_{t-1} + u_t \quad (2)$$

onde:

- δt representa a tendência determinística
- r_t é um passeio aleatório
- ε_t é o erro estacionário

O componente:

$$r_t = r_{t-1} + u_t \quad (3)$$

onde:

- r_t : componente não estacionário da série
- r_{t-1} : valor anterior desse componente
- u_t : inovação aleatória no instante t

O teste KPSS utiliza as seguintes hipóteses:

- Hipótese Nula (H_0): A série é estacionária, Equação 1 ($\gamma < 0$)
- Hipótese Alternativa (H_1): A série não é estacionária (possui raiz unitária, Equação 1 $\gamma = 0$)

Ruído branco:

$$\varepsilon_t \sim (0, \sigma^2), \quad E[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2 \quad (4)$$

5.5 Estrutura da série temporal

Estrutura aditiva:

$$Y_t = T_t + S_t + R_t \quad (5)$$

Onde:

- Y_t : valor observado no tempo t (concentração de CO_2 no mês t);
- T_t : tendência que representa o comportamento de longo prazo da série (aumento contínuo de CO_2 ao longo do período);
- S_t : sazonalidade que representa padrões periódicos que se repetem ao longo dos meses;
- R_t : componente aleatória da série, não explicada pela tendência nem pela sazonalidade (ruído ou variações imprevisíveis).

5.6 Critérios de informação

Informação de Akaike (AIC):

$$AIC = -2 \log(L) + 2k \quad (6)$$

em que:

- L representa a função de verossimilhança do modelo;
- k representa o número de parâmetros estimados.

O Critério de Informação de Akaike corrigido (AICc):

$$AICc = AIC + \frac{2k(k+1)}{n-k-1} \quad (7)$$

em que:

- n representa o tamanho da amostra;
- k representa o número de parâmetros estimados.

Informação Bayesiano (BIC):

$$BIC = -2 \log(L) + k \log(n) \quad (8)$$

em que:

- L representa a função de verossimilhança do modelo;
- k representa o número de parâmetros estimados;
- n representa o tamanho da amostra.

5.7 Modelos candidatos

5.7.1 SNAIVE

$$\hat{Y}_{t+h|t} = Y_{t+h-m(k+1)} \quad (9)$$

onde:

$\hat{Y}_{t+h}$ previsão para o horizonte h ;

Y_t valor observado da série no instante t ;

m período sazonal da série temporal;

h horizonte de previsão;

k número de ciclos sazonais completos entre a observação e a previsão.

5.7.2 ETS

$$Y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t \quad (10)$$

onde:

Y_t valor observado da série temporal no instante t ;

ℓ_t componente de nível (level), que representa o valor médio da série ao longo do tempo;

b_t componente de tendência (trend), responsável por capturar o crescimento ou declínio da série;

s_t componente sazonal (seasonal), que descreve padrões periódicos recorrentes;

m período sazonal da série temporal;

ε_t termo aleatório (erro), assumido com média zero e variância constante.

5.7.3 ARIMA

$$\phi(B)(1-B)^d Y_t = \theta(B)\varepsilon_t \quad (11)$$

onde:

B operador de defasagem, definido por $BY_t = Y_{t-1}$;

$\phi(B)$ polinômio autoregressivo de ordem p ;

$\theta(B)$ polinômio de médias móveis de ordem q ;

d ordem de diferenciação regular;

Y_t valor observado da série temporal;

ε_t termo aleatório (ruído branco).

5.7.4 SARIMA

$$\Phi(B^s) \phi(B) (1 - B)^d (1 - B^s)^D Y_t = \Theta(B^s) \theta(B) \varepsilon_t \quad (12)$$

- B é o operador de defasagem, definido por $BY_t = Y_{t-1}$;
- s representa o período sazonal da série temporal;
- $\phi(B)$ representa o polinômio autoregressivo não sazonal;
- $\theta(B)$ representa o polinômio de médias móveis não sazonal;
- $\Phi(B^s)$ representa o polinômio autoregressivo sazonal;
- $\Theta(B^s)$ representa o polinômio de médias móveis sazonal;
- d corresponde à ordem de diferenciação regular;
- D corresponde à ordem de diferenciação sazonal;
- ε_t representa um processo de ruído branco com média zero e variância constante.

5.8 Critérios de previsão

Erro percentual médio – EPM

$$EPM = \frac{100}{n} \sum_{t=1}^n \left(\frac{Y_t - \hat{Y}_t}{Y_t} \right) \quad (13)$$

Y_t valor observado no instante t ;

$\hat{Y}_t$ valor previsto no instante t ;

n número de observações.

Erro quadrático médio – EQM

$$EQM = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2 \quad (14)$$

Y_t valor observado no instante t ;

$\hat{Y}_t$ valor previsto no instante t ;

n número de observações.

Erro absoluto médio – EAM

$$EAM = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| \quad (15)$$

Y_t valor observado no instante t ;

$\hat{Y}_t$ valor previsto no instante t ;

n número de observações.

Erro percentual absoluto médio – EPAM

$$EPAM = \frac{100}{n} \sum_{t=1}^n \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right| \quad (16)$$

Y_t valor observado no instante t ;

$\hat{Y}_t$ valor previsto no instante t ;

n número de observações.

5.9 Avaliação residual dos modelos ajustados

Testes de Portmanteau

Teste de Box-Pierce:

$$Q_{BP} = n \sum_{k=1}^h \hat{\rho}_k^2 \quad (17)$$

em que:

- n representa o tamanho da amostra;
- h representa o número máximo de defasagens (*lags*) avaliadas;
- $\hat{\rho}_k$ representa a autocorrelação residual estimada no lag k .

Teste de Ljung-Box:

$$Q_{LB} = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k} \quad (18)$$

em que:

- n representa o tamanho da amostra;
- h representa o número máximo de defasagens avaliadas;
- $\hat{\rho}_k$ representa a autocorrelação residual estimada no lag k .

Sob a hipótese nula de ausência de autocorrelação serial residual, ambas as estatísticas seguem aproximadamente uma distribuição qui-quadrado com graus de liberdade ajustados pelo número de parâmetros estimados no modelo.

Valores- p superiores ao nível de significância adotado indicam ausência de evidências para rejeição da hipótese nula, sugerindo que os resíduos apresentam comportamento compatível com ruído branco.

5.10 Versão utilizada do Rstudio

Primeiramente, é importante alertar que, a não ser quando relatado o contrário, os resultados e as análises foram realizadas no software RStudio (Posit Team, 2026), versão 2026.04.0 por meio de funções disponíveis na linguagem R e em suas bibliotecas padrão. Todos os gráficos como dados estatísticos da análise realizada, foi escrita através do *overleaf* LaTeX online o que permitiu gerar este relatório em PDF.

6 Resultados

6.1 Série temporal da concentração de CO_2

Primeiramente, foi realizada uma análise descritiva da série por meio da visualização da concentração de CO_2 na atmosfera ao longo dos anos, bem como das funções de autocorrelação (FAC) e autocorrelação parcial (FACP), conforme apresentado na Figura 1.




Figura 1: Série temporal da concentração de CO_2

No gráfico da Série Temporal, observou-se uma tendência crescente ao longo do todo o período analisado. A série original não se mostrou estacionária, uma vez que a Função de Autocorrelação (FAC) apresentou decaimento lento, indicando a presença de dependência temporal persistente e possíveis componentes de tendência e sazonalidade. Por sua vez, a Função de Autocorrelação Parcial (FACP) apresentou um pico significativo na primeira defasagem, sugerindo a existência de uma estrutura autorregressiva de baixa ordem.

6.2 Estatística resumo

6.2.1 Estatística resumo da concentração de CO_2

As estatísticas descritivas da concentração de CO_2 foram apresentadas na Tabela 1. De modo geral, as medidas obtidas indicaram comportamento relativamente estável em termos distributivos, uma vez que média e mediana apresentaram valores próximos, sugerindo baixo assimetria dos dados.

Tabela 1: Estatísticas descritivas da concentração de CO_2

Mínimo	1º Quartil	Mediana	Média	3º Quartil	Máximo
313.2	323.5	335.2	337.1	350.3	366.8

Entretanto, a elevada amplitude entre os valores mínimo e máximo sugere considerável variação da concentração de CO_2 ao longo do período analisado, possivelmente associada à presença de tendência crescente observada na série temporal. Além disso, os quartis indicaram uma evolução gradual dos níveis de concentração, não havendo evidências iniciais de valores atípicos extremos.

6.3 Identificação de padrões sazonais

6.3.1 Dados mensais, média e desvio padrão – concentração CO_2

As estatísticas mensais da concentração de CO_2 , apresentadas na Tabela 2 evidenciaram a presença de sazonalidade ao longo do ano. Observou-se que os maiores valores médios ocorreram entre os meses de abril a junho, com destaque para o mês de maio, que apresentou média aproximada de 340 ppm. Em contrapartida, os menores valores médios foram observados nos meses de setembro e outubro, ambos com média em torno de 334 ppm.

Tabela 2: Média e desvio padrão mensal da concentração de CO_2

Mês	Média	Desvio padrão
Jan	336	15.0
Fev	337	15.0
Mar	338	15.1
Abr	339	15.2
Mai	340	15.2
Jun	339	15.1
Jul	338	15.0
Ago	336	14.9
Set	334	14.8
Out	334	14.9
Nov	335	15.0
Dez	337	15.2

Além disso, os desvios padrão mensais apresentaram valores semelhantes ao longo do ano, variando aproximadamente entre 14.8 e 15.2. Esse comportamento sugere estabilidade na variabilidade da série temporal, indicando que a amplitude das oscilações sazonais permaneceu relativamente constante durante o período analisado. De maneira geral, os resultados reforçam a presença de sazonalidade anual na concentração de CO_2 , caracterizada por padrões recorrentes entre os meses do ano, sem evidências iniciais de mudanças expressivas na dispersão sazonal dos dados.

6.4 Gráfico Heatmap

A seguir com o objetivo de explorar o padrão sazonal, a componente de tendência foi removida, permitindo uma avaliação mais clara do comportamento sazonal dos dados. Inicialmente, observa-se regiões em cinza nas extremidades da Figura 2 devido à ausência de estimativas da componente de tendência nos pontos iniciais e finais da série. Esse comportamento ocorre porque a decomposição clássica utiliza médias móveis centralizadas, o que impossibilita o cálculo completo da tendência nas bordas temporais.




Figura 2: Heatmap sem tendência concentração de CO_2

Perceba que o *heatmap* apresentado na Figura 2 ilustra um comportamento que indica sazonalidade bem definida, com padrão sazonal ao longo do período analisado. Esse resultado está consistente com as estatísticas mensais apresentadas na Tabela 2 que indicaram maiores concentrações médias de CO_2 entre os meses de abril a junho, com destaque para maio. Em contrapartida, os menores níveis médios foram nos meses de setembro e outubro. Tais padrões podem ser visualizados na Figura 2 por meio da intensidade das cores do *heatmap*, que refletem as variações sazonais da concentração de CO_2 ao longo do ano. Dessa forma, a análise gráfica reforça e corrobora os resultados anteriormente obtidos por meio das estatísticas descritivas mensais.

6.5 Avaliando a estacionariedade da série temporal

6.5.1 Teste de Dickey-Fuller Aumentado (ADF)

Em seguida, foi aplicado o Teste de Dickey-Fuller Aumentado (ADF) descrito na Equação 1 com objetivo de verificar a presença de raiz unitária na série temporal. Esse teste permitiu avaliar a estacionariedade da série e identificar a possível necessidade de aplicação de diferenciações para a remoção de tendências estocásticas. Para isso, consideraram-se as seguintes hipóteses:

- Hipótese Nula (H_0): A série apresenta raiz unitária (série não estacionária, $\gamma = 0$)
- Hipótese Alternativa (H_1): Série estacionária ($\gamma < 0$)

A hipótese de presença de raiz unitária foi avaliada por meio do teste ADF, cujos resultados são apresentados na Tabela 3. Os resultados não forneceram evidências suficientes para rejeitar

Tabela 3: Resultados do Teste de Dickey-Fuller Aumentado

Série	Estatística ADF	Valor-p
Dados CO_2	-2.8299	0.2269

a hipótese nula H_0 , indicando a presença de raiz unitária da série. Dessa forma, concluiu-se que a série original não é estacionária.

6.5.2 Teste de Kwiatkowski-Phillips-Schmidt-Shin (KPSS)

Foi aplicado o teste *Kwiatkowski-Phillips-Schmidt-Shin* (KPSS) descrito na Equação 2 para avaliar a estacionariedade da série e complementar os resultados obtidos pelo teste ADF. Para isso, foram consideradas as seguintes hipóteses:

- Hipótese Nula (H_0): A série é estacionária, Equação 2 ($\gamma < 0$)
- Hipótese Alternativa (H_1): Série não estacionária (Há raiz unitária, Equação 2 ($\gamma = 0$))

Tabela 4: Resultados do Teste KPSS

Série	Estatística KPSS	Valor-p
Dados CO_2	7.8173	< 0.01

Os resultados apresentados na Tabela 4 forneceram evidências para a rejeição da hipótese H_0 em favor de H_1 (estatística KPSS = 7.8173; $p < 0.01$). Dessa forma, concluiu-se que a série não apresentava estacionariedade, corroborando os resultados vistos anteriormente no teste ADF.

Tabela 5: Hipóteses dos testes ADF e KPSS

Teste	H_0	H_1
ADF	Não estacionária	Estacionária
KPSS	Estacionária	Não estacionária

Os testes ADF e KPSS foram aplicados com o objetivo de avaliar a estacionariedade da série temporal. Conforme evidenciado pelos resultados apresentados previamente nas Tabelas 3 e Tabela 4, ambos os testes indicaram evidências de não estacionariedade na série de concentração de CO_2 . A convergência entre os resultados obtidos pelos dois procedimentos pode ser observada na Tabela 5. Dessa forma, concluiu-se que a série original não apresentava características de estacionariedade.

6.6 Série temporal decomposta – concentração CO_2

6.6.1 Métodos de decomposição

A decomposição da série temporal foi realizada com o objetivo de compreender melhor sua estrutura ao longo do período analisado. De acordo com a literatura, o método clássico de decomposição apresenta algumas limitações, o que o torna menos recomendado em aplicações atuais. Em contrapartida, métodos mais avançados, como X-11, SEATS, Holt-Winters e STL,

oferecem abordagens mais sofisticadas para a identificação e interpretação de padrões presentes em séries temporais.

6.6.2 Estrutura do modelo da série (Aditiva)

Para nosso caso, adotou-se a decomposição STL (Seasonal and Trend decomposition using Loess)¹ por ser adequada a séries em que a amplitude das variações sazonais se mantém constante com o nível da série ao longo do período analisado. Essa característica pôde ser observada na Figura 3 justificando a adoção da estrutura aditiva apresentada na Equação 5.




Figura 3: Série temporal decomposta da concentração de CO_2

A decomposição STL foi aplicada diretamente à série original, sem a utilização de transformação logarítmica, uma vez que a série de concentração de CO_2 apresentou baixa variabilidade ao longo do período analisado, sem evidências de aumento da amplitude das oscilações à medida que o nível da série se elevava. Dessa forma, não foram observados indícios de comportamento multiplicativo que justificassem a aplicação de transformações para estabilização da variância.


Além disso, o método STL é vantajoso, destacando-se sua flexibilidade para lidar com diferentes padrões sazonais, a possibilidade de acomodar mudanças graduais na componente sazonal ao longo do tempo e pode ser robusto a presença de *outliers*. Essas características tornam o método particularmente adequado para a série analisada, que apresentou baixa variabilidade e ausência de estruturas estocásticas complexas.

6.7 Gráfico dos resíduos e FAC da decomposição do modelo STL


Observou-se que o componente residual (*remainder*) da decomposição STL, apresentado na Figura 4a, oscila em torno de zero, o que sugere a ausência de viés sistemático no modelo. Além disso, não foram observadas evidências fortes de heterocedasticidade, uma vez que a amplitude dos resíduos permanece relativamente estável ao longo do período analisado. Entretanto, verifica-se a presença de resíduos extremos, os quais podem estar associados a eventos atípicos, choques externos ou fatores não capturados pelo modelo. Por sua vez, a FAC apresentada na Figura 4b

¹Loess é um método de suavização não paramétrico utilizado para estimar relações não lineares em séries temporais.

evidenciou uma autocorrelação positiva significativa na primeira defasagem $Lag(1)$ com valor 0,41 indicando dependência temporal de curto prazo entre resíduos. Adicionalmente, o padrão oscilatório observado na função de autocorrelação sugere a possível presença de componentes sazonais remanescentes e de uma estrutura autorregressiva (AR), indicando que a parte da dependência temporal ainda não foi completamente capturada pela decomposição.



(a) Resíduos da decomposição STL



(b) FAC dos resíduos da decomposição STL

Figura 4: Avaliação residual da decomposição STL

Conclui-se que os resíduos não constituem um ruído branco, sugerindo a necessidade de refinamento do modelo. Entre as possíveis estratégias, destacam-se a inclusão de componentes sazonais, o aumento da ordem autorregressiva e se necessário, a aplicação de diferenciação, visando eliminar a dependência temporal ainda presente nos resíduos.

6.8 Série temporal da concentração de CO_2 com diferenciação

Após a aplicação da diferenciação regular e sazonal, conforme apresentado na Figura 5, a FAC exibiu um rápido decaimento das autocorrelações, indicando uma redução da não estacionariedade da série. Entretanto, observou-se a presença de autocorrelação sazonal significativa no $Lag(12)$. Por sua vez, a FACP apresentou picos significativos nos $Lags$ sazonais 12, 24, 36 e 48, com magnitudes decrescentes à medida que a defasagem aumenta, sugerindo a persistência de uma estrutura sazonal autoregressiva. Em conjunto, esses resultados indicam que modelos SARIMA com componentes sazonais são potencialmente adequados para representar a dinâmica temporal da série.




Figura 5: Série temporal da concentração de CO_2 diferenciada

6.9 Avaliando a estacionariedade da série temporal com diferenciação

6.9.1 Teste de Dickey-Fuller Aumentado (ADF)

Após a aplicação das diferenciações regular e sazonal, os testes de estacionariedade ADF e KPSS foram novamente aplicados à série transformada. Os resultados encontram-se apresentados na Tabela 6. O teste ADF produziu uma estatística igual a -8.9846 com p-valor inferior a 0.05, levando à rejeição da hipótese nula de presença de raiz unitária e indicando que a série diferenciada pode ser considerada estacionária. Complementarmente, o teste KPSS apresentou estatística igual a 0.0115 com p-valor igual a 0.10, não rejeitando a hipótese nula de estacionariedade ao nível de significância de 5%.

Tabela 6: Resultados dos testes de estacionariedade para a série diferenciada

Teste	Estatística	Lag	p-valor
ADF	-8.9846	7	0.01
KPSS	0.0115	5	0.10

Dessa forma, ambos os testes passaram a indicar evidências favoráveis à estacionariedade da série após a aplicação das diferenciações. Adicionalmente, a análise das funções de autocorrelação (FAC) e autocorrelação parcial (FACP) indicou que a estrutura temporal remanescente da série é compatível com a modelagem por meio de modelos SARIMA, conforme definido na Equação 12. Portanto, conclui-se que a série diferenciada apresenta as condições necessárias para a etapa de identificação e estimação desses modelos.

6.10 Análise inferencial

Dando continuidade à análise, foram ajustados modelos candidatos de previsão com o objetivo de avaliar seu desempenho em comparação ao modelo de referência *benchmark* SNAIVE 9. Para essa finalidade, foram considerados o modelo de suavização exponencial ETS 10 e o modelo SARIMA 12, em virtude de sua ampla utilização na modelagem de séries temporais que apresentam componentes sazonais e padrões estruturais bem definidos.

6.10.1 Critérios de informação

Os modelos candidatos foram inicialmente comparados por meio dos critérios de informação AIC6, AICc7 e BIC8, os quais avaliam simultaneamente a qualidade do ajuste e a parcimônia dos modelos. Em geral, menores valores desses critérios indicam um melhor equilíbrio entre capacidade explicativa e complexidade do modelo.

O resultados dos critérios de informação para os modelos candidatos são apresentados na Tabela 7. Nota-se que o modelo SNAIVE apresentou valores não disponíveis (NA) para todos os critérios de informação. Isso ocorre porque, diferentemente dos modelos ETS e SARIMA, o SNAIVE não envolve a estimação de parâmetros por meio de procedimentos de máxima verossimilhança, limitando-se a reproduzir o comportamento observado no período sazonal anterior. Como os critérios AIC, AICc e BIC dependem do valor da função de verossimilhança e do

número de parâmetros estimados, tais medidas não podem ser calculadas para esse modelo pelo *software* utilizado.

Tabela 7: Critérios de informação dos modelos candidatos

Modelo	AIC	AICc	BIC
SNAIVE	NA	NA	NA
ETS	1662	1663	1736
ARIMA	167	167	192
SARIMA	167	167	192

Embora os modelos ARIMA e SARIMA tenham apresentado valores idênticos para os critérios de informação AIC, AICc e BIC, conforme apresentado na Tabela 7, optou-se por selecionar o modelo SARIMA como modelo final. Essa escolha é justificada pela presença de sazonalidade mensal identificada ao longo das etapas exploratórias da análise, incluindo a decomposição da série, o mapa de calor sazonal e a inspeção das funções de autocorrelação (FAC) e autocorrelação (FACP).

Além disso, os testes de estacionariedade e a necessidade de aplicação de diferenciação sazonal evidenciaram que a dinâmica temporal da série não poderia ser adequadamente descrita apenas por componentes não sazonais. O modelo selecionado, SARIMA $(1, 1, 1)(1, 1, 2)_{12}$, incorpora explicitamente termos autoregressivos e de médias móveis sazonais, permitindo representar a dependência observada entre meses separados por um ciclo anual.

Dessa forma, embora os critérios de informação não permitam distinguir os modelos em termos de qualidade de ajuste, a adoção do modelo SARIMA mostra-se consistente com a estrutura sazonal identificada nos dados e com as evidências obtidas nas etapas de diagnóstico da série temporal. Considerando os resultados obtidos nesta etapa, os modelos ETS e SARIMA foram selecionados para a etapa subsequente de avaliação preditiva e comparação de desempenho.

6.11 Critério de previsão dos modelos

6.11.1 EPM, EQM, EAM e EPAM

Após a seleção inicial baseada nos critérios de desempenho EPM 13, EQM 14, EAM 15 e EPAM 16 os modelos foram avaliados quanto à capacidade preditiva. Para essa finalidade, a série foi particionada em um conjunto de treinamento, composto pelas observações mensais do período de 1959 a 1996, e um conjunto de teste, correspondente às observações do ano de 1997. As métricas de desempenho foram calculadas com base nas previsões obtidas para o conjunto de teste, sendo que menores valores dessas medidas indicam melhor desempenho preditivo do modelo.

Tabela 8: Critérios de previsão dos modelos avaliados.

Modelo	EPM	EQM	EAM	EPAM
SNAIVE	0.3110	1.470	1.130	0.311
ETS	-0.0362	0.216	0.365	0.100
SARIMA	-0.0861	0.217	0.393	0.108

A Tabela 8 evidencia que os modelos ETS e SARIMA apresentaram desempenho preditivo substancialmente superior ao modelo SNAIVE. Este último apresentou os maiores valores de EPM, EQM, EAM e EPAM, indicando erros de previsão significativamente maiores em comparação aos demais modelos.

Entre os modelos avaliados, o ETS apresentou os menores valores de EQM (0.216), EAM (0.365) e EPAM (0.100), evidenciando o melhor desempenho preditivo no conjunto de teste. Além disso, o valor de EPM mais próximo de zero (-0.0362) sugere menor viés sistemático nas previsões quando comparado aos modelos SNAIVE e SARIMA.

Dessa forma, embora os critérios de informação (AIC, AICc e BIC) tenham indicado preferência pelo modelo SARIMA, os resultados da avaliação fora da amostra (*backtesting*) demonstram que o modelo ETS apresentou desempenho preditivo ligeiramente superior para o horizonte de previsão considerado. Assim, o modelo ETS foi selecionado como o modelo mais adequado para a realização das previsões finais da série.

6.12 Diagnóstico dos resíduos

6.12.1 Resíduos do modelo – SARIMA

A seguir são apresentadas os diagnósticos dos resíduos do modelo SARIMA $(1, 1, 1)(1, 1, 2)_{12}$. A Figura 6 apresenta os principais gráficos de diagnósticos residual do modelo ajustado. Observa-se que os resíduos encontram-se distribuídos aleatoriamente em torno de zero, sem evidências visuais de tendência, sazonalidade remanescente ou padrões sistemáticos não capturados pelo modelo. Outro ponto são a dispersão dos resíduos permanece relativamente constante ao longo do período analisado, não indicando evidências visuais relevantes de heterocedasticidade e apresentando comportamento compatível com a hipótese de variância constante.




Figura 6: Diagnóstico de resíduos modelo SARIMA

A Função de Autocorrelação (FAC) dos resíduos apresentou a maior parte dos coeficientes dentro dos limites de confiança, indicando que a dependência temporal presente na série original foi adequadamente capturada pelo modelo. Embora tenha sido observado um coeficiente ligeiramente significativo no $Lag(9)$, não foi identificado padrão persistente de autocorrelação residual, sugerindo a ausência de dependência temporal remanescente relevante.

O histograma dos resíduos apresentou distribuição aproximadamente simétrica e centrada em

zero. De forma complementar, o gráfico QQ-Plot indicou que os quantis empíricos acompanham satisfatoriamente a reta teórica da distribuição normal, embora pequenas discrepâncias tenham sido observadas nas caudas da distribuição. E conjunto, esses resultados fornecem evidências de que os resíduos do modelo SARIMA apresentam comportamento compatível com um processo de ruído branco e atendem, de forma satisfatória, aos pressupostos de independência e normalidade aproximada dos erros.

6.13 Testes de Portmanteau – Box-Pierce e Ljung-Box

6.13.1 Ruído branco – SARIMA

A Figura 7 apresenta resultados dos testes de Portmanteau, Box Pierce 17 e Ljung-Box 18 aplicados aos resíduos do modelo SARIMA $(1, 1, 1)(1, 1, 2)_{12}$. Esses testes foram utilizados com o objetivo de verificar se os resíduos apresentam comportamento compatível com um processo de ruído branco 4. Em particular, a figura apresenta os valores-p obtidos para diferentes defasagens consideradas nos testes.




Figura 7: Teste para ruído branco modelo SARIMA

Observa-se que, para a maioria das defasagens *Lags* analisados, os valores-p permaneceram acima do nível de significância de 5%, não fornecendo evidências para rejeitar a hipótese nula de ausência de autocorrelação residual. Adicionalmente, verifica-se que os valores-p tendem a aumentar à medida que o número de defasagens consideradas cresce, reforçando a evidência de que a dependência temporal presente na série foi adequadamente capturada pelo modelo. Em conjunto, esses resultados sugerem que os resíduos do modelo SARIMA apresentam comportamento compatível com um processo de ruído branco.

6.13.2 Resíduos do modelo – ETS

Após a análise dos critérios de informação e das métricas de desempenho preditivo, apresentados nas Tabelas 7 e 8, respectivamente, procede-se à etapa de diagnóstico do modelo selecionado. O objetivo desta análise é verificar se os resíduos apresentam comportamento compatível com um processo de ruído branco, isto é, $(\varepsilon_t \sim N(0, \sigma^2))$, condição desejável para indicar que a estrutura temporal da série foi adequadamente capturada pelo modelo.

A figura 8 apresenta os diagnósticos residuais do modelo ETS. Observa-se que os resíduos oscilam aleatoriamente em torno de zero ao longo do período analisado, sem evidências visuais

de tendência, sazonalidade remanescente ou outros padrões sistemáticos que possam indicar inadequação do ajuste.




Figura 8: Diagnóstico de resíduos modelo ETS

A Função de Autocorrelação (FAC) dos resíduos apresentou apenas alguns coeficientes ligeiramente significativos, sem evidências de um padrão persistente de dependência temporal. Esse resultado sugere que o modelo foi capaz de capturar adequadamente a estrutura temporal presente na série.

O histograma dos resíduos apresentou distribuição aproximadamente simétrica e centrada em zero. Complementarmente, o gráfico QQ-Plot indicou boa aderência dos resíduos à distribuição normal teórica, uma vez que os pontos se mantiveram próximos à reta de referência, com pequenas discrepâncias observadas apenas nas caudas da distribuição.

Em conjunto, esses resultados fornecem evidências de que os resíduos do modelo ETS apresentam comportamento compatível com um processo de ruído branco. Dessa forma, conclui-se que o modelo atende de forma, satisfatória, aos pressupostos de independência e normalidade aproximada dos erros, mostrando-se adequado para fins de previsão.

6.13.3 Ruído branco – ETS

A Figura 9 apresenta resultados dos testes de Portmanteau, Box-Pierce 17 e Ljung-Box 18 aplicados aos resíduos do modelo ETS. Esses testes foram utilizados para avaliar a hipótese de que os resíduos constituem um ruído branco 4, ou seja, que não apresentam autocorrelação serial significativa. Para diferentes defasagens analisadas, a Figura apresenta os respectivos valores-p obtidos em cada teste.




Figura 9: Teste para ruído branco modelo ETS

Observa-se que, para parte dos *Lags* analisados, os valores-p permaneceram abaixo do nível de significância de 5%, fornecendo evidências para a rejeição da hipótese nula de ausência de autocorrelação residual. Embora os valores-p tenham ultrapassado esse limiar para defasagens mais elevadas, os resultados indicam a presença de dependência temporal remanescente nos resíduos, sugerindo que o modelo não foi capaz de capturar integralmente a estrutura temporal da série.

Dessa forma, apesar do bom desempenho preditivo observado anteriormente, os diagnósticos residuais indicam que o modelo ETS apresenta limitações quanto ao atendimento dos pressupostos de independência dos erros. Em comparação, o modelo SARIMA apresentou resíduos mais compatíveis com um processo de ruído branco, evidenciando maior adequação estatística sob a perspectiva dos diagnósticos residuais.

6.14 Resultados do teste de Ljung-Box para os modelos ajustados

A análise diagnóstica dos resíduos foi realizada para os modelos SARIMA e ETS por meio de inspeção gráfica e aplicação do teste de Ljung-Box, cujos resultados são apresentados na Tabela 9. O objetivo dessa etapa foi avaliar a presença de autocorrelação residual e verificar a adequação dos modelos ajustados.

Observou-se que ambos os modelos apresentaram valores-p superiores ao nível de significância de 5%. Para o modelo SARIMA $(1, 1, 1)(1, 1, 2)_{12}$ obteve-se valor-p igual a 0.407, enquanto para o modelo ETS o valor-p foi de 0.195. Dessa forma, não foram encontradas evidências estatísticas suficientes para rejeitar a hipótese nula de ausência de autocorrelação residual em nenhum dos modelos.

Em conjunto, esses resultados indicam que os resíduos dos modelos SARIMA e ETS apresentam comportamento compatível com um processo de ruído branco, sugerindo que ambos foram capazes de capturar adequadamente a estrutura temporal presente na série.

Tabela 9: Resultados do teste de Ljung-Box para os modelos ajustados

Modelo	Estatística Ljung-Box	Valor-p
SARIMA(1, 1, 1)(1, 1, 2) ₁₂	19.8	0.407
ETS	29.7	0.195

Esses resultados indicam que ambos os modelos foram capazes de capturar adequadamente a

estrutura temporal da série, produzindo resíduos compatíveis com ruído branco. No entanto, o modelo SARIMA apresentou valor-p superior ao observado para o modelo ETS, sugerindo melhor adequação residual. Dessa forma, considerando conjuntamente os resultados dos diagnósticos residuais e a capacidade de representar explicitamente a estrutura sazonal da série, o modelo SARIMA foi selecionado como modelo final para a análise da concentração mensal de CO_2 .

6.15 Previsões dos modelos – SNAIVE, SARIMA e ETS

6.15.1 Previsão do modelo benchmark SNAIVE

O modelo SNAIVE, apresentado na Figura 10 foi utilizado como modelo de referência *benchmark*, assumindo que a previsão para cada período corresponde ao valor observado no mesmo mês do ano anterior. Por sua simplicidade, esse modelo estabelece um nível mínimo de desempenho esperado, de modo que modelos mais sofisticados devem apresentar erros de previsão inferiores para justificar sua utilização.




Figura 10: Previsão modelo SNAIVE da concentração de CO_2

Observe que a sazonalidade anual é preservada pelo modelo, uma vez que as previsões para períodos futuros correspondem, essencialmente, à repetição dos valores observados nos mesmos meses do último ano disponível. Como o método não incorpora uma modelagem explícita da tendência, as previsões refletem apenas o padrão sazonal histórico da série, apresentando comportamento mais conservador para horizontes de previsão mais longos.

6.15.2 Parâmetros estimados modelo ETS

O procedimento automático de seleção identificou o modelo ETS (M,Ad,M) 10 como a melhor especificação de suavização exponencial mais adequada para a série de concentração mensal de CO_2 . Esse modelo é caracterizado pela combinação de erro multiplicativo, tendência aditiva amortecida e sazonalidade multiplicativa. Seus componentes de nível, tendência e sazonalidade são atualizados recursivamente por meio dos parâmetros de suavização α , β e γ , respectivamente. Adicionalmente, a presença de tendência amortecida requer a estimação do parâmetro ϕ , responsável por reduzir progressivamente a influência da tendência à medida que o horizonte de previsão aumenta, evitando projeções excessivamente otimistas ou pessimistas no longo prazo.

Tabela 10: Parâmetros estimados do modelo ETS (M,Ad,M)

Parâmetro	Estimativa
α (nível)	0.6824
β (tendência)	0.0415
γ (sazonalidade)	0.0003
ϕ (amortecimento)	0.9773

A Tabela 10 apresenta os parâmetros estimados do modelo ETS (M,Ad,M): $\alpha = 0.6824$, $\beta = 0.0415$, $\gamma = 0.0003$ e $\phi = 0.9773$. O valor relativamente elevado de α indica que as observações mais recentes exercem influência considerável na atualização do componente de nível da série. Por outro lado, o baixo valor de β sugere que o componente de tendência é atualizado de forma lenta e gradual ao longo do tempo.

O parâmetro sazonal γ apresentou valor muito próximo de zero, indicando que a estrutura sazonal anual permaneceu praticamente estável durante o período analisado, exigindo poucos ajustes ao longo do processo de estimação. Já o parâmetro de amortecimento ϕ foi estimado em 0.9773, evidencia a presença de uma tendência amortecida, na qual o efeito da tendência é progressivamente reduzido à medida que o horizonte de previsão aumenta. Consequentemente, o modelo projeta a continuidade de crescimento observado na série, porém com intensidade gradualmente decrescente em previsões de longo prazo.

6.15.3 Previsão do modelo ETS

A Figura 11 apresenta as previsões geradas pelo modelo ETS. Os resultados indicam continuidade do crescimento da concentração de CO_2 , preservando a estrutura sazonal multiplicativa observada ao longo da série histórica. Além disso, a incorporação de uma tendência amortecida permite que o crescimento projetado ocorra de forma gradual e suavizada, evitando extrapolações excessivas e mantendo coerência com o comportamento histórico dos dados.




Figura 11: Previsão modelo ETS da concentração de CO_2

6.15.4 Parâmetros estimados modelo SARIMA

O modelo selecionado para a série de concentração mensal de CO_2 foi o SARIMA $(1,1,1)(1,1,2)_{12}$. A estrutura contempla uma componente autorregressiva não sazonal de primeira ordem, uma componente de médias móveis não sazonal de primeira ordem, bem como componentes autorregressiva e de médias móveis sazonais com periodicidade de 12 meses.

Os parâmetros estimados foram $\phi_1 = 0.2569$, $\theta_1 = -0.5847$, $\Phi_1 = -0.5489$, $\Theta_1 = -0.2620$ e $\Theta_2 = -0.5123$. O coeficiente autorregressivo positivo sugere a presença de persistência temporal de curto prazo, indicando que valores observados em períodos recentes exercem influência sobre observações subsequentes. O coeficiente de médias móveis negativo sugere que choques aleatórios ocorridos em períodos anteriores são parcialmente compensados nos períodos seguintes.

Os parâmetros sazonais evidenciam a existência de dependência temporal associada ao ciclo anual da série, corroborando os padrões sazonais identificados durante a análise exploratória a na etapa de identificação do modelo. A variância residual estimada foi $\sigma^2 = 0.08576$, indicando que a variabilidade não explicada pelo modelo permaneceu relativamente baixa após o ajuste.

Tabela 11: Parâmetros estimados do modelo SARIMA(1,1,1)(1,1,2)₁₂.

Parâmetro	Estimativa	Erro-padrão
AR(1)	0.2569	0.1406
MA(1)	-0.5847	0.1204
SAR(1)	-0.5489	0.5880
SMA(1)	-0.2620	0.5701
SMA(2)	-0.5123	0.4819

6.15.5 Previsão do modelo SARIMA

De forma similar, a Figura 12 apresenta as previsões geradas pelo modelo SARIMA (1,1,1)(1,1,2)₁₂. Observa-se que o modelo reproduziu adequadamente a estrutura temporal da série, capturando tanto a dependência temporal de curto prazo quanto os efeitos sazonais anuais. As previsões obtidas indicam uma trajetória crescente da concentração de CO_2 , acompanhada por um padrão sazonal consistente ao longo do horizonte de previsão de três anos.




Figura 12: Previsão modelo SARIMA da concentração de CO_2

Em termos comparativos, os modelos ETS e SARIMA produziram previsões bastante semelhantes, indicando robustez dos resultados e concordância quanto à continuidade da tendência de crescimento da concentração atmosférica de CO_2 . Considerando conjuntamente os critérios de desempenho preditivo, os diagnósticos dos resíduos e a capacidade de representar explicitamente a estrutura temporal da série, o modelo SARIMA(1,1,1)(1,1,2)₁₂ mostrou-se o mais adequado ao ajuste dos dados, capturado satisfatoriamente suas principais características. Dessa forma, o modelo SARIMA é considerado o mais plausível para ser adotado como modelo final para fins de previsão.

7 Conclusão

Os resultados obtidos evidenciaram que a série temporal da concentração mensal de CO₂ apresenta tendência crescente de longo prazo e forte componente sazonal anual. A análise exploratória, complementada pelos gráficos de autocorrelação (FAC) e autocorrelação parcial (FACP) Figura 1, indicou a presença simultânea de dependência temporal e sazonalidade, justificando o uso de modelos capazes de representar ambas as estruturas.

Após a aplicação das diferenciações regular e sazonal, os testes ADF e KPSS 6 confirmaram a estacionariedade da série transformada, permitindo o ajuste adequado dos modelos de previsão. Entre os modelos avaliados, SNAIVE, ETS, ARIMA e SARIMA, observou-se desempenho substancialmente inferior do modelo SNAIVE, tanto em termos de ajuste quanto de capacidade preditiva, o que já era esperado dada sua natureza ingênua.

Os modelos ETS (M,Ad,M) e SARIMA(1,1,1)(1,1,2)₁₂ apresentaram os melhores resultados segundo os critérios de informação 7 e as métricas de previsão 8. Em particular, o modelo ETS apresentou os menores valores de EQM, EAM e EPAM no conjunto de teste, indicando maior precisão preditiva. No entanto, as diferenças em relação ao modelo SARIMA foram pequenas.

A análise residual 6 8 indicou que ambos os modelos produziram resíduos aproximadamente não correlacionados, com distribuição próxima da normalidade e variância aproximadamente constante ao longo do tempo. Os testes de Ljung-Box 9 e Portmanteau 7 9 não forneceram evidências suficientes para rejeitar a hipótese de independência dos resíduos, sugerindo que a estrutura temporal da série foi adequadamente capturada pelos modelos ajustados.

As previsões para os três anos subsequentes preservaram a tendência crescente e o padrão sazonal característicos da série. Além disso, as trajetórias previstas pelos modelos ETS 11 e SARIMA 12 mostraram-se bastante semelhantes, reforçando a consistência dos resultados obtidos.

Por fim, embora o modelo ETS tenha apresentado desempenho preditivo ligeiramente superior, optou-se pela adoção do modelo SARIMA(1,1,1)(1,1,2)₁₂ como modelo final. Essa escolha fundamenta-se em sua capacidade de representar explicitamente as dependências temporais e sazonais identificadas na série, além de apresentar diagnósticos residuais adequados e resultados consistentes nas etapas de análise, produzindo previsões coerentes com a dinâmica histórica da concentração atmosférica de CO₂.

Referências

- Azevedo, Caio L. N. (2024). **ME607-Séries Temporais**. Disponível em: https://www.ime.unicamp.br/~cnaber/Aula_ARIMA_P1_ST_ME607_1S_2024.pdf.
- Morettin, P. A.,Toloi, C. M. C. (2018).**Análise de Séries Temporais**(Volume 1). Editora Blucher.
- E. E. Holmes, M. D. Scheuerell, and E. J. Ward(2021). **Applied Time Series Analysis for Fisheries and Environmental Sciences**. Disponível em: <https://atsa-es.github.io/atsa-labs/index.html>.